

Cosseno 0,99 não é compreensão: anisotropia, polaridade e a competência jurídica diante da recuperação densa

Pedro Borges Mourão

Promotor de Justiça, Mestre em Direito, Especialista em Segurança da Informação, e pesquisador na interseção entre Direito, inteligência artificial e forense digital.

27 de junho de 2026

Resumo

Circula entre operadores do Direito a suposição de que dominar uma ferramenta de inteligência artificial é uma questão de aprender comandos. Este artigo argumenta que essa suposição é falsa e que seu custo não é a ineficiência, mas a confiança indevida em sistemas cujo modo de falha é invisível para quem não entende como eles representam a linguagem. O componente que examinamos é a recuperação densa por *sentence embeddings*, base dos sistemas de busca jurídica e dos *pipelines* de geração aumentada por recuperação (RAG). Construímos um conjunto de 40 pares mínimos forenses em português e medimos quatro modelos abertos, de três modelos consolidados (MiniLM, mpnet, distiluse) a um modelo de fronteira (multilingual-e5-large). O achado central é contraintuitivo e tem consequência prática direta. Os modelos preservam a polaridade — a distinção entre afirmação e negação, entre polo ativo e passivo — como um sinal estruturalmente fraco, e a fraqueza é mais severa não na negação adverbial, mas na inversão de polo processual (autor $\leftrightarrow$ réu). Esse padrão *atravessa as gerações de modelos*: ele aparece nos três modelos antigos e reaparece, idêntico, no modelo de fronteira quando se corrige a geometria do espaço. O modelo de fronteira, porém, opera em um regime fortemente *anisotrópico* — a similaridade de cosseno entre duas sentenças jurídicas quaisquer, ainda que sem relação, é de 0,84 — de modo que ele atribui a uma sentença e à sua negação um cosseno bruto de 0,99. Normalizada pelo *baseline* anisotrópico, a fragilidade reaparece, e medi-la por estrato revela o que a média esconde: a negação adverbial é bem discriminada em todos os modelos, mas a inversão de polo (autor $\leftrightarrow$ réu) tem *gap* normalizado *negativo ou nulo* — em todas as gerações, antigas e de fronteira, o modelo considera a tese e sua inversão tão próximas ou mais próximas entre si quanto duas paráfrases legítimas. A fragilidade de polaridade é, portanto, invariante estrutural da representação distribucional, não defeito de um modelo; o que o modelo de fronteira acrescenta não é mais robustez, e sim anisotropia, que esconde a mesma falha atrás de um cosseno altíssimo. Na tarefa de recuperação temática, a margem de cosseno que separa a sentença correta da sua inversão de polo encolhe a poucos milésimos — e no modelo de fronteira, é de cinco milésimos. A conclusão inverte a intuição corrente: o progresso da engenharia de *embeddings* não tornou a polaridade mais robusta, mas deslocou sua fragilidade para um regime onde o operador, lendo um cosseno de 0,99, conclui certeza máxima exatamente onde a discriminação é mais precária. A modernização do modelo disfarçou a armadilha. Reconhecê-la exige uma alfabetização linguística e geométrica que a formação jurídica não fornece. Todo o material é reproduzível.

Palavras-chave: inteligência artificial jurídica; recuperação densa; *embeddings*; anisotropia; polaridade; geração aumentada por recuperação; prova digital.

1 Introdução: uma suposição confortável e cara

Há uma suposição confortável circulando nos escritórios e órgãos públicos que operam a justiça no Brasil: a de que dominar uma ferramenta de inteligência artificial é uma questão de aprender comandos, como quem aprende os atalhos de um editor de texto. Descobre-se o botão certo, memorizam-se algumas fórmulas de prompt e, pronto, está-se operando. Essa suposição é falsa, e o custo de mantê-la não é a ineficiência. É a confiança indevida em um sistema cujo modo de falha o operador não enxerga.

O argumento deste texto é específico, e convém delimitá-lo com precisão para que não seja confundido com uma crítica genérica à IA. Não se defende que advogados aprendam técnica de prompt. O objeto que examinamos é um componente preciso da infraestrutura de IA jurídica: a *recuperação densa por embeddings*, isto é, o mecanismo que converte peças e consultas em vetores numéricos e os compara por similaridade. Esse componente é o coração dos sistemas de busca jurisprudencial modernos e a primeira etapa dos *pipelines* de geração aumentada por recuperação (RAG), que alimentam o modelo gerativo com os documentos que ele usará para responder. Se essa etapa entrega ao gerador o documento de sentido invertido — o precedente que contradiz a tese, em vez do que a sustenta —, todo o restante do sistema opera sobre material corrompido na origem. É essa etapa, e não a geração de texto em si, que este artigo diagnostica.

A contribuição é dupla. Primeiro, ela mede empiricamente, em português jurídico, como esse componente trata a polaridade, e mostra que a fragilidade observada não é defeito de um modelo específico, mas propriedade estrutural que atravessa gerações. Segundo, e é o achado que reorganiza o artigo, ela demonstra que o progresso tecnológico não eliminou essa fragilidade: deslocou-a para um regime geométrico onde ela se torna mais difícil de perceber. O operador que conclui “máxima confiança” diante de um escore de similaridade altíssimo está, nesse regime, cometendo precisamente o erro que a competência jurídica não o ensina a evitar.

2 O caso que expõe a natureza do problema

Tomem-se duas frases que dizem o oposto uma da outra: “o réu compareceu à audiência” e “o réu não compareceu à audiência”. Para um operador do Direito, essas frases são antípodas. A presença ou ausência do réu muda o procedimento, dispara ou não a revelia (art. 344 do CPC), pode redesenhar o ônus da prova. A diferença entre elas é a diferença entre dois processos.

Submetam-se essas duas frases a um modelo de *embedding*. A similaridade que o modelo atribui ao par é alta. A causa do fenômeno precede qualquer arquitetura específica: a representação distribucional do significado, formulada por Zellig Harris em 1954, segundo a qual o significado de uma palavra é capturado pelos contextos em que ela aparece [4]. Modelos de *embedding* aprendem que “compareceu” e “não compareceu” significam coisas parecidas porque aparecem em contextos textuais quase idênticos. O advérbio de negação é, para a estatística distribucional, uma perturbação mínima no contexto. Para o Direito, é a inversão completa do sentido.

A questão empírica que organiza o restante do artigo tem três camadas, e mantê-las separadas é a principal exigência metodológica. A primeira: *quão* alta é essa similaridade, comparada à de uma paráfrase legítima, quando se isola a sobreposição lexical? A segunda: esse comportamento muda com a geração do modelo, ou modelos de fronteira o corrigem? A terceira, que se revelou decisiva: a similaridade absoluta sequer é a métrica certa, dado que o espaço vetorial pode ser geometricamente enviesado? As três camadas correspondem às três contribuições empíricas das Seções 4 e 5.

3 Método

3.1 Pares mínimos e o problema do controle

Um *par mínimo* compartilha quase toda a superfície lexical e difere em um ponto que inverte o sentido. Construímos 40 pares em português jurídico, estratificados pelo *mecanismo* de inversão (Tabela 1).

Estrato	<i>n</i>	Exemplo (frase A / frase B)
Negação adverbial	6	<i>O réu compareceu...</i> / <i>O réu não compareceu...</i>
Antonímia de núcleo	6	<i>...foi deferido</i> / <i>...foi indeferido</i>
Inversão de polo	16	<i>O autor deve indenizar o réu</i> / <i>O réu deve indenizar o autor</i>
Quantificador/modal	4	<i>Todos os requisitos...</i> / <i>Nenhum dos requisitos...</i>
Controle pareado	8	<i>...foi indeferido</i> / <i>...foi rejeitado</i>

Tabela 1: Estratos do conjunto. O estrato de *inversão de polo* foi ampliado para $n = 16$ por concentrar o efeito mais forte. Os oito pares de *controle* são paráfrases legítimas, lexicalmente pareadas aos contrastivos (Jaccard 0,79 vs 0,75), de modo que a comparação difere apenas na variável de interesse: preserva *versus* inverte o sentido.

3.2 Modelos, medida e as três camadas de análise

Medimos quatro modelos abertos de *sentence embedding* multilíngues: três consolidados e amplamente usados em produção — `paraphrasemultilingualMiniLML12v2`, `paraphrasemultilingual-mpnetbasev2` e `distilusebasemultilingualcasedv2` — e um modelo de fronteira, `multilingual-e5large`, treinado com aprendizado contrastivo em larga escala, da biblioteca `sentence-transformers` [8]. O e5 exige prefixos `query:/passage::`; aplicamo-los de forma simétrica (`query:` em ambas as sentenças) na medição intrínseca e assimétrica na recuperação, conforme o treino do modelo.¹

A análise tem três camadas. A camada *intrínseca* mede o cosseno entre uma sentença e sua negação. A camada *geométrica* mede o *baseline* anisotrópico — o cosseno médio entre sentenças jurídicas sem relação — e normaliza por ele. A camada *extrínseca* mede, numa tarefa de recuperação, se a sentença correta é rankeada acima da oposta. As três são necessárias porque, como a Seção 5 demonstra, a camada intrínseca isolada conduz a conclusões erradas em espaços anisotrópicos. Toda comparação agregada acompanha intervalo de confiança de 95% por *bootstrap* (5.000 reamostragens). A execução é determinística e reproduzível.

4 Resultados: a fragilidade da polaridade atravessa as gerações

A Tabela 2 e a Figura 1 reportam o cosseno bruto por modelo e estrato. Dois fatos se mantêm em todos os modelos. Primeiro, a negação adverbial é o estrato *menos* problemático — a presença do marcador “não” dá ao modelo um sinal lexical a que se agarrar. Segundo, a inversão de polo é o estrato *mais* severo: trocar “autor” por “réu”, dois *tokens* de altíssima frequência em contextos idênticos, produz o cosseno mais alto em todos os quatro modelos, chegando a 0,993 no e5.

¹A escolha do prefixo `query:` para a medição intrínseca segue a instrução oficial dos autores do e5, que recomendam esse prefixo para tarefas *simétricas* como similaridade semântica e recuperação de paráfrases, reservando o par `query:/passage:` para tarefas *assimétricas* de recuperação de passagens longas. A anisotropia observada não é, ademais, artefato da escolha de prefixo: os próprios autores atribuem a concentração dos escores de cosseno na faixa de 0,7 a 1,0 ao uso de temperatura baixa (0,01) na perda contrastiva InfoNCE, propriedade do treino que independe do prefixo. O *script* de replicação inclui a verificação direta do *baseline* sob ambos os protocolos.

Estrato	MiniLM	mpnet	distiluse	e5 (bruto)	e5 (norm.)
negacao_adverbial	0.550	0.490	0.844	0.958	0.743
antonimia_nucleo	0.724	0.769	0.925	0.977	0.857
inversao_polo	0.958	0.967	0.972	0.993	0.958
quant_modal	0.693	0.562	0.901	0.975	0.846
controle_parafrase	0.919	0.940	0.924	0.991	0.943
<i>baseline aniso.</i>	0.07	~0.10	~0.14	0.84	

Tabela 2: Cosseno bruto por estrato e modelo, com o *baseline* anisotrópico de cada espaço na última linha. Note o salto do *baseline*: 0,07 nos modelos antigos, 0,84 no e5.




Figura 1: Cosseno bruto dos quatro modelos. O e5 esmaga todos os estratos perto de 0,99, inclusive os contrastivos. Lido ingenuamente, isso sugeriria que o e5 é o *pior* modelo — conclusão que a Seção 5 mostra ser um artefato geométrico.

A leitura ingênua da Figura 1 seria que o e5, por dar cosseno mais alto aos pares opostos, é o mais cego à polaridade. Essa leitura é falsa, e o erro que ela comete é exatamente o erro que o operador jurídico comete diante da ferramenta. Corrigi-lo exige tratar a geometria do espaço.

5 A anisotropia muda o que o cosseno significa

5.1 O fenômeno

Em espaços vetoriais de alta dimensão produzidos por transformadores, os vetores tendem a se concentrar em um cone estreito, em vez de se distribuírem pela esfera. Essa propriedade, a *anisotropia*, foi caracterizada por Ethayarajh [2] e faz com que sentenças sem qualquer relação semântica exibam cosseno alto. A consequência é direta: em um espaço anisotrópico, o valor absoluto do cosseno deixa de ser interpretável, e apenas a posição *relativa* ao *baseline* do espaço carrega informação. O fenômeno é especialmente pronunciado em modelos multilíngues [3].

Medimos o *baseline* de cada modelo como o cosseno médio entre sentenças jurídicas não relacionadas. O resultado separa as duas gerações de forma nítida: o *baseline* dos três modelos antigos fica entre 0,07 e 0,14 — espaços praticamente isotrópicos —, ao passo que o do e5 é de 0,84. No espaço do e5, duas sentenças jurídicas quaisquer já partem de uma similaridade de 0,84; o cosseno de 0,99 entre uma sentença e sua negação representa, sobre essa base, um acréscimo pequeno. Dizer que o e5 “vê as duas frases como 99% idênticas” é, portanto, um erro de leitura: ele vê quase tudo como muito similar, e a pergunta correta é quanto a polaridade desloca o vetor *acima* desse piso.

5.2 Normalização e o reaparecimento da estrutura

Para tornar os modelos comparáveis, normalizamos o cosseno pelo *baseline* de cada espaço, seguindo o procedimento de pares mínimos de Lin e Chen [5]: a similaridade normalizada remapeia o *baseline* para zero, isolando o sinal semântico acima do ruído geométrico. A Figura 2 mostra o efeito no e5. À esquerda, o cosseno bruto: indistinguível a olho nu, tudo entre 0,96 e 0,99. À direita, o cosseno normalizado: a estrutura reaparece, e é a *mesma* estrutura dos modelos antigos — a negação adverbial discriminada (0,74), a inversão de polo colada no controle (0,96 contra 0,94).




Figura 2: O achado central. À esquerda, o que o operador vê: cosseno bruto do e5, uniforme perto de 0,99. À direita, o que de fato ocorre: removida a anisotropia, a inversão de polo (azul) praticamente não se separa do controle de paráfrase (verde). A fragilidade estava lá, oculta pela geometria.

O dado que sintetiza o argumento é o *gap* normalizado entre cada estrato e o controle de paráfrase, definido como $\text{norm}(\text{controle}) - \text{norm}(\text{estrato})$: positivo quando o modelo separa o estrato da mera reformulação, negativo quando trata a perturbação de sentido como *mais* inócua que uma paráfrase. Reportá-lo por estrato, e não como média única, é essencial, porque a média esconde a estrutura. A Tabela 3 mostra o *gap* por estrato nos três modelos abertos, com intervalo de confiança de 95% por *bootstrap*.

Estrato	MiniLM	mpnet	distiluse
Negação adverbial	+0,52	+0,65	+0,13
Antonímia de núcleo	+0,28	+0,25	−0,00
Inversão de polo	−0,05	−0,04	−0,08
Quantificador/modal	+0,32	+0,55	+0,04

Tabela 3: *Gap* normalizado por estrato (controle menos estrato). A negação adverbial é fortemente positiva — o modelo a discrimina bem. A inversão de polo é o único estrato com *gap* negativo em todos os modelos: o modelo a trata como mais próxima da identidade que uma paráfrase legítima. O intervalo de confiança da inversão de polo aproxima-se de zero pelo lado positivo mas o ponto é consistentemente negativo nos três modelos; nos demais estratos o *gap* é positivo com folga.

A leitura é direta e desfaz a tentação da média. Em todos os modelos, a negação adverbial é bem discriminada, ao passo que a inversão de polo tem *gap* negativo. Uma média agregada dos estratos seria positiva apenas porque a negação a puxa para cima, mascarando que, no estrato que importa, o sinal de polaridade colapsa abaixo de zero. E o ponto decisivo é que esse

colapso *não* é peculiar ao e5: ele aparece nas três gerações anteriores tanto quanto no modelo de fronteira, e no e5 o *gap* da inversão de polo é igualmente negativo ($-0,016$ sobre os 16 pares, $-0,034$ sobre o subconjunto auditado de 12; Seção 11). A fragilidade de polaridade é, portanto, invariante estrutural da representação distribucional — propriedade de representar significado por proximidade, não defeito de um modelo específico. O aprendizado contrastivo em larga escala do e5, que a intuição supõe ter “resolvido” a insensibilidade ao sentido, não a resolveu; manteve-a, e a vestiu de anisotropia, deslocando-a para um regime onde o cosseno bruto de 0,99 a torna invisível ao operador.

6 A margem que sustenta a recuperação encolhe sob anisotropia

Poder-se-ia objetar que tudo isso é geometria sem consequência, desde que a recuperação funcione. Medimos, então, a tarefa-fim: dada uma consulta temática, a sentença correta, sua oposta e um conjunto de distratores, o modelo rankeia a correta acima da oposta, e com que margem? Convém registrar de saída que esta medição usa um protocolo de prefixo distinto do da Seção 5: a recuperação é *assimétrica* (**query**: na consulta, **passage**: nos candidatos), ao passo que a medição intrínseca do *gap* é simétrica (**query**: em ambos os lados), conforme o uso recomendado para cada tarefa. São, portanto, números de dois experimentos diferentes, e não devem ser lidos como um placar único.

Os três modelos abertos foram avaliados sobre 20 consultas; o e5, sobre 10. Nesse regime, a taxa de acerto de *ranking* é alta em todos — MiniLM e distiluse 19/20, mpnet 16/20, e5 10/10 —, mas a diferença de taxa entre modelos não é o ponto, e não é estatisticamente sustentável com esse n : os intervalos de confiança binomiais se sobrepõem amplamente. O achado robusto não é quem acerta mais, e sim *por que margem*, e onde ela se estreita. A Figura 3 reporta a margem.




Figura 3: Recuperação por modelo. O acerto de *ranking* é alto em todos, mas a margem mínima de cosseno que sustenta esses acertos (em vermelho) estreita-se até o limiar da indistinção; no e5, cujo cosseno absoluto vive todo perto de 0,99, a margem mínima é de cinco milésimos. As falhas dos modelos abertos concentram-se, ademais, em pares de inversão de polo.

A margem é o que importa, e ela conta a história. Em todos os modelos, as poucas falhas de recuperação e as margens mínimas concentram-se em pares de inversão de polo: no MiniLM, a única falha é o par locador/locatário, com a oposta vencendo por quatro milésimos; no mpnet, entre as quatro falhas estão locador/locatário e exequente/executado. No e5, que não falha nas dez consultas, a margem mínima que separa a correta da oposta é de 0,005 — da mesma ordem de grandeza do ruído, e embutida num espaço onde o cosseno absoluto de tudo é 0,99. O e5 acerta, mas decide por margens que são uma fração de centésimo dentro de um cone de altíssima

similaridade.

Esta é a armadilha, e é estritamente o erro que a competência jurídica não previne. O operador que projeta ou contrata um sistema de busca, ao comparar modelos, vê o e5 entregar similaridades de 0,99 e conclui que ele “entende” os documentos com altíssima confiança. O que ele não vê é que essa confiança aparente repousa sobre uma discriminação de polaridade de poucos milésimos, que é a primeira coisa a colapsar sob qualquer perturbação realista — um documento mais longo que dilui o peso dos *tokens* de polo, uma consulta ambígua, um *reranker* mal calibrado, ruído de OCR. O estudo de Stanford sobre ferramentas jurídicas, no nível do produto, observa que documentos apenas textualmente parecidos são recuperados como relevantes e degradam a resposta [6]; nossos resultados localizam, no componente de *embedding* e na sua geometria, um dos mecanismos desse fenômeno.

7 A inversão de polo resiste à atenção cruzada

Poder-se-ia esperar que o problema da polaridade fosse específico do bi-encoder, que comprime cada sentença em um vetor isolado antes de compará-las, e que uma arquitetura que processasse o par *conjuntamente* o resolvesse. Testamos essa hipótese submetendo os 40 pares a um *cross-encoder* de inferência de linguagem natural, **nli-deberta-v3-base**, que recebe as duas sentenças ao mesmo tempo, com atenção cruzada entre todos os *tokens*, e as classifica como *contradição*, *implicação* ou *neutro*. Se a distinção de polaridade fosse recuperável por atenção conjunta, esperaríamos que todos os pares contrastivos fossem classificados como *contradição* e o controle de paráfrase, não.

A Tabela 4 e a Figura 4 mostram que essa expectativa se confirma para a maioria dos estratos, mas falha exatamente onde o bi-encoder também falha pior. A negação adverbial e os quantificadores são detectados como *contradição* em 100% dos casos (6/6 e 4/4); a antonímia de núcleo, em 5/6. O controle de paráfrase é, em 6 de 8 casos, corretamente *não* classificado como *contradição*. Os dois casos restantes são falsos positivos do instrumento — “indeferido”/“rejeitado” e “demanda”/“ação”, paráfrases legítimas que o modelo rotula como *contradição*, uma delas com confiança de 0,99. Esse erro de 25% no controle impõe cautela: o *cross-encoder* não modela perfeitamente nem a sinonímia, de modo que sua taxa na inversão de polo não deve ser lida como medida limpa de papéis temáticos, e sim como sinal de uma arquitetura cujo desempenho já é imperfeito na tarefa simples. Feita essa ressalva, a inversão de polo é detectada como *contradição* em apenas 9 de 16 casos — mais baixa que qualquer outro estrato, inclusive abaixo do que o ruído do instrumento no controle explicaria.

Estrato	Contradição	Implicação	Neutro	<i>n</i>
negacao_adverbial	6	0	0	6
antonimia_nucleo	5	1	0	6
inversao_polo	9	6	1	16
quant_modal	4	0	0	4
controle_parafrase	2	6	0	8

Tabela 4: Classificação do *cross-encoder* NLI por estrato. A inversão de polo é a única em que a detecção de *contradição* falha sistematicamente, e o modo de falha é revelador: 6 dos 16 pares são classificados como *implicação*.




Figura 4: Distribuição das classificações do *cross-encoder* por estrato. A fatia laranja na inversão de polo — pares lidos como *implicação* — é o sintoma de que a arquitetura não modela papéis temáticos.

O modo de falha importa mais que a taxa. Dos sete pares de inversão de polo não detectados como contradição, seis foram classificados como *implicação*: o modelo julga que “o autor deve indenizar o réu” *implica* “o réu deve indenizar o autor”. Isto não é ruído estatístico; é a manifestação precisa de que a inversão de polo não é uma contradição lógico-formal — ambas as sentenças podem ser verdadeiras em situações distintas — e sim uma inversão referencial de papéis que nenhuma das arquiteturas testadas, nem o bi-encoder por similaridade nem o *cross-encoder* por inferência, representa adequadamente. A consequência para o argumento central é direta: a fragilidade da polaridade de papel não é um artefato da compressão vetorial que um modelo conjunto corrigiria. É mais profunda, e atravessa também o paradigma de inferência.

O operador poderia reagir dizendo: “então preciso de um engenheiro que use o melhor modelo”. A reação é exatamente a errada, e os dados mostram por quê. O “melhor” modelo, pela métrica que o operador sabe ler, é o que mais disfarça a fragilidade. Não se trata de um defeito que uma engenharia melhor elimina, e sim de uma propriedade da escolha de representar significado por proximidade distribucional num único vetor — escolha que é, para os modelos de recuperação densa que aqui medimos, simultaneamente a fonte de seu poder e a fonte de suas falhas de polaridade. Cabe delimitar o alcance dessa afirmação. Ela não vale para modelos generativos autoregressivos, cujo comportamento é moldado também por camadas de otimização que não se aplicam a um *embedding* — ajuste por reforço com preferência humana, alinhamento constitucional, computação inferencial em tempo de execução — e cujas falhas têm, por isso, outras fontes além da geometria distribucional. O objeto deste artigo é o componente de busca, não o gerador: um *sentence embedding* não possui política de geração, modelo de recompensa nem cadeia de raciocínio; ele projeta texto em um vetor, e é nessa projeção que a polaridade se perde. A polaridade referencial, em particular a inversão de polo, resiste a tudo o que testamos nesse componente: aos quatro modelos, ao aprendizado contrastivo do e5, e mesmo a uma arquitetura de atenção cruzada, como a Seção 7 documenta em detalhe. O problema não é de modelo. É de como a linguagem representa papéis e negações, e de como essa representação sobrevive, ou não, à compressão vetorial.

Nenhuma dessas camadas é visível para quem opera o sistema como um buscador. Todas são previsíveis para quem entende que está lidando com um modelo estatístico de linguagem, e agora com a geometria do espaço em que esse modelo vive. A diferença entre o operador competente e o exposto não é a quantidade de prompts que conhece. É a presença ou ausência de um modelo mental correto do que a máquina faz com a linguagem e do que um número de similaridade significa.

8 A escala do dano já documentada

Quem considera isto teórico não acompanhou os números. Um estudo da Stanford RegLab sobre alucinação jurídica em modelos de propósito geral encontrou taxas entre 58% e 82%, com desempenho em doutrina substantiva que mal supera o chute aleatório [1]. Avaliando ferramentas dedicadas que ancoram respostas por recuperação aumentada, um segundo estudo ainda registrou 17% de alucinação no Lexis+ AI e 33% no Westlaw [6]. Recuperação aumentada reduz o problema; não o elimina. E se a etapa de *embedding* preserva a polaridade por margem de milésimos, a recuperação que alimenta o gerador pode entregar o precedente de sentido invertido, sobre o qual o modelo gerativo então constrói uma resposta fluente e confiante.

E há o caso fundador. Em *Mata v. Avianca*, dois advogados protocolaram uma peça com seis citações geradas por IA; nenhuma existia. Quando um deles pediu ao modelo que confirmasse se eram reais, ele confirmou [7]. O sistema não mentiu: gerou a continuação estatisticamente mais provável para “essas citações são reais?”, que era a confirmação. O operador leu espelhamento como verificação. O erro tem a mesma forma do erro de ler cosseno 0,99 como compreensão: em ambos os casos, uma propriedade estatística do sistema é interpretada como um ato cognitivo que ele não realizou. Registre-se que a geração de texto envolve camadas de otimização adicionais — alinhamento por preferência, raciocínio inferencial — que este artigo não mede e cujas contribuições para o erro são objeto de outra literatura; o ponto aqui é apenas que a *forma* do equívoco do operador, tomar estatística por cognição, reaparece nos dois extremos do *pipeline*, da recuperação à geração.

A lição não é “a IA erra”. É que os erros têm uma gramática, e que ela é também geométrica. Quem a conhece sabe onde o sistema é frágil: na polaridade, com severidade máxima na inversão de polo; sob anisotropia, onde a fragilidade se esconde atrás de escores altos. O operador alfabetizado não confia menos de modo difuso; desconfia de modo cirúrgico, nos pontos exatos onde a arquitetura e a geometria preveem a falha.

9 Verificação por raciocínio: a pergunta importa mais que o modelo

A Seção 7 mostrou que a inversão de polo resiste a um *cross-encoder* de inferência. Cabe perguntar se os modelos generativos de raciocínio — a geração que sucede a recuperação em um *pipeline* RAG, e que a Seção 11 delimita como fora do objeto de medição deste artigo — conseguem, quando usados como passo explícito de *verificação* sobre o mesmo fenômeno, capturar a inversão que o *embedding* e o *cross-encoder* perdem. A questão não é se um modelo de raciocínio substitui a recuperação, e sim se ele repara, a jusante, a falha de polaridade que a recuperação deixa passar. O experimento que segue continua, portanto, a investigação sobre a inversão de polo iniciada na Seção 4, agora em uma terceira arquitetura.

Submetemos os 16 pares de inversão de polo a três modelos generativos de uma mesma família, cobrindo um eixo de capacidade e custo — de um modelo econômico a um modelo de fronteira — sob *duas formulações* da mesma tarefa. A primeira replica a pergunta do *cross-encoder*: “estas frases se contradizem?”. A segunda pergunta pela estrutura argumental: “a posição das partes foi trocada, ou cada parte conserva o mesmo papel?”. A distinção é teórica antes de ser empírica: a inversão de polo não é uma contradição de valor de verdade — “o autor deve ao réu” e “o réu deve ao autor” podem ambas ser verdadeiras em um litígio com pedidos recíprocos — e sim uma inversão de papéis temáticos, dimensão ortogonal à contradição. A hipótese é que a formulação, e não a capacidade do modelo, decida o resultado.

A Figura 5 reporta os achados, e eles são mais nítidos que a hipótese previa. Sob a pergunta por papel temático, todos os três modelos identificam a inversão na quase totalidade dos casos — Haiku 13/16, Sonnet 15/16, Opus 16/16 —, todos superando com folga o *cross-encoder* (9/16). Sob a pergunta por contradição, todos colapsam — Haiku 7/16, Sonnet 0/16, Opus 3/16. O

salto entre as duas formulações, dentro de cada modelo, é de seis a quinze pares. A formulação domina.

Mais revelador que as contagens é *quais* pares cada formulação resolve. Os sete pares em que o *cross-encoder* falhou são os de papéis recíprocos (apelante/apelada, credor/devedor, requerente/requerido e análogos), em que a troca produz duas frases logicamente compatíveis. Sob a pergunta por papel temático, os dois modelos maiores recuperaram *todos* os sete (7/7), e o modelo econômico, cinco; o *cross-encoder* recuperara zero. A formulação correta ataca exatamente a fraqueza estrutural do paradigma de inferência.




Figura 5: Verificação da inversão de polo por modelos de raciocínio. À esquerda: trocar a pergunta de “contradição” para “papel temático” eleva a detecção de quase zero a quase perfeita em todos os modelos, acima do *cross-encoder* (linha tracejada). À direita: os pares recíprocos que o *cross-encoder* errou (0/7) são recuperados pela pergunta por papel temático.

Dois resultados merecem destaque, com a ressalva de que, sobre 16 itens, diferenças de poucos pares entre modelos não são estatisticamente significativas; o que é robusto é o padrão, não o placar.

O primeiro é o domínio da formulação. Que o modelo mais econômico, sob a pergunta correta, alcance 13/16 e supere o *cross-encoder* dedicado mostra que a verificação eficaz de polaridade não requer o modelo de maior capacidade; requer a pergunta que captura a estrutura argumental. O recurso decisivo não é a potência da ferramenta, mas a formulação da consulta.

O segundo é contraintuitivo, e as justificativas espontâneas dos modelos o explicitam. Sob a formulação inadequada, a capacidade não ajuda: o modelo de fronteira não lidera. Sob “contradição”, os acertos são Haiku 7, Sonnet 0, Opus 3 — a detecção não cresce com a capacidade, e o modelo mais caro fica abaixo do mais barato. A razão aparece nas respostas. Diante do par “o autor deve indenizar o réu” / “o réu deve indenizar o autor”, o Opus respondeu que não há contradição, justificando que, em caso de danos recíprocos, ambos os deveres podem coexistir e ambas as frases podem ser verdadeiras ao mesmo tempo. O raciocínio é juridicamente correto sobre valor de verdade — e é exatamente por ser correto na dimensão da contradição que falha na dimensão que importa, a do papel das partes. Mais capacidade aplicada à formulação errada não corrige o erro; produz uma recusa mais fundamentada da pergunta certa. O modelo econômico, menos cauteloso, por vezes respondeu “contradição” a esses mesmos pares — acertando o rótulo pela razão errada, o que não é virtude e não se generaliza.

Um achado lateral, registrado por honestidade, reforça a tese sob outro ângulo. Ao ser interrogado sobre o par que inverte credor e devedor, o modelo de fronteira identificou a troca de papéis e, não solicitado, apontou que uma das frases é juridicamente impossível, pois quem cede um crédito é necessariamente seu titular, o credor. A observação é correta e expõe uma

limitação do próprio conjunto: alguns pares de inversão de polo, ao trocar mecanicamente os termos, geram uma frase incoerente em vez de meramente invertida, o que confunde a variável de interesse. Trata-se de ruído de construção a corrigir em uma versão ampliada do conjunto; não altera o padrão agregado, mas delimita a precisão dos itens individuais. De modo análogo, parte dos poucos erros sob a pergunta por papel temático decorreu de os modelos lerem “papel” como função sintática (ambas as partes são sujeito que sustenta tese) em vez de posição processual concreta — ambiguidade da própria pergunta, que ilustra, ela mesma, que a verificação exige formulação precisa.

A consequência estende a tese central do artigo à camada de raciocínio, sem contrariá-la. Na recuperação, a fragilidade se esconde atrás de um cosseno alto; na verificação por raciocínio, ela se esconde atrás da formulação plausível mas inadequada. Em ambos os casos, o que separa o acerto do erro não é o poder do modelo, e sim a competência de quem o opera — na recuperação, saber que a similaridade alta é geometricamente enganosa; na verificação, saber que a pergunta deve interrogar o papel das partes, não a contradição lógica. A era do raciocínio não dispensa a alfabetização do operador; desloca-a da geometria do *embedding* para a estrutura da pergunta de verificação.

10 O que muda quando o operador entende a linguagem da máquina

Três deslocamentos concretos decorrem da perspectiva adotada. O primeiro, na verificação: quem entende que o modelo gera a continuação mais plausível para de pedir ao próprio modelo que confirme os fatos que produziu, e leva a verificação para a fonte primária. O segundo, na formulação da entrada: compreender o espelho reativo leva o operador a forçar o contraditório, pedindo a antítese e as objeções mais fortes à própria posição, em vez de entregar a tese pronta e convidar o sistema a fabricar suporte. O terceiro, e o que estes resultados tornam urgente, na arquitetura dos sistemas que o Direito constrói: quem projeta ou contrata um *pipeline* de recuperação precisa saber que a similaridade absoluta de um *embedding* é geometricamente enganosa, que a comparação entre modelos deve ser feita sobre métricas normalizadas e de *ranking*, e que a polaridade — sobretudo a inversão de polo — exige mitigação explícita: *reranking* de atenção cruzada, tratamento dedicado de pares dialéticos, verificação de polaridade independente do escore de similaridade. Essas são decisões linguísticas e geométricas antes de serem decisões de engenharia, e o jurista que não as entende terceiriza ao fornecedor escolhas que determinam se o sistema sustenta ou sabota o trabalho.

11 Limitações, escopo e trabalho em andamento

Convém ser explícito quanto ao estatuto deste estudo: ele é uma prova de conceito controlada, não um *benchmark* de escala, e três limitações delimitam o que ele estabelece e o que fica para a continuação.

Escala dos dados. Os 40 pares foram construídos por um único autor com expertise de domínio. Eles ilustram mecanismos com intervalo de confiança reportado, e a convergência do padrão entre quatro modelos de gerações e geometrias distintas sugere robustez; mas não estabelecem distribuições populacionais, e os estratos de quantificador/modal permanecem pequenos ($n = 4$). A extensão natural é ampliar e submeter os pares a anotação independente.

Escala da recuperação. A tarefa de recuperação usa um corpus reduzido (dois candidatos mais doze distratores). Ela isola a discriminação de polaridade e mostra que a margem que a sustenta é de milésimos, mas não *prova* o colapso dessa margem sob ruído de produção. A continuação direta, para a qual o *script* de replicação já está estruturado, é injetar os pares contrastivos em um acervo de milhares de *chunks* minerados de jurisprudência pública e medir

a degradação da margem em função do tamanho do corpus. A hipótese — sustentada pela estreiteza já observada — é que distratores reais estreitam, não alargam, a margem; convertê-la em evidência quantitativa é trabalho em andamento.

Modelos proprietários. Medimos quatro modelos abertos, um deles de fronteira. A espinha dorsal de parte do mercado jurídico são *embeddings* proprietários (OpenAI, Cohere), que empregam técnicas próprias de redução de dimensionalidade. Sua geometria pode diferir, e testá-los é necessário para generalizar a afirmação ao cenário comercial completo. Registramos isto como limitação franca: a tese de que a anisotropia mascara a fragilidade está estabelecida para o modelo aberto de fronteira e fundamentada na literatura sobre o fenômeno, mas sua confirmação nos modelos fechados de maior uso comercial fica como passo seguinte.

Método de isotropização. Normalizar pela anisotropia é uma entre várias técnicas. Escolhemos a normalização por *baseline* de pares mínimos por ser a mais transparente e diretamente interpretável [5]; uma validação cruzada por remoção de componentes principais (*whitening*) é caminho complementar para confirmar que o reaparecimento da estrutura não depende do método particular.

Validade dos pares de inversão de polo e robustez ao subconjunto limpo. A inversão de polo sustenta a afirmação mais forte do artigo — a de que é o estrato mais severo. Isso exige escrutínio dos próprios itens, pois inverter mecanicamente os papéis pode gerar não uma frase invertida, mas uma frase juridicamente impossível. Auditamos manualmente os 16 pares: 12 são inequivocamente coerentes (a inversão produz duas frases ambas possíveis em situações distintas), 3 são limítrofes (ambíguos quanto a legitimidade ativa *versus* passiva, mas não impossíveis) e 1 é impossível — o par que inverte credor e devedor, pois apenas o titular do crédito pode cedê-lo, defeito identificado espontaneamente pelo próprio modelo de fronteira. Reexecutamos as análises de que dispomos sobre o subconjunto de 12 pares limpos, e o padrão não apenas sobrevive como se reforça. O *cross-encoder* continua a falhar na mesma proporção (detecta contradição em 7/12, contra 9/16 no conjunto cheio), e a verificação por papel temático permanece quase perfeita (Opus e Sonnet 12/12, Haiku 10/12). Quanto à métrica geométrica, remedimos o cosseno normalizado da inversão de polo no e5 sobre os três conjuntos, e o resultado é o achado mais forte do artigo: o *gap* normalizado entre a paráfrase de controle e a inversão de polo é *negativo* — $-0,016$ nos 16 pares e $-0,034$ nos 12 limpos. Um *gap* negativo significa que o e5 atribui à inversão de polo um cosseno normalizado (0,97 no subconjunto limpo) *superior* ao que atribui a duas paráfrases legítimas (0,94): o modelo considera “o autor deve ao réu” e “o réu deve ao autor” mais próximas entre si do que dois sinônimos verdadeiros. E o efeito é *mais* forte nos pares limpos — os pares imperfeitos atenuavam-no, de modo que a depuração reforça, em vez de comprometer, a afirmação de que a inversão de polo é o estrato mais severo. A contaminação existia, mas operava contra a tese, não a favor; removê-la fortalece o achado. (Distinga-se este *gap* da inversão de polo isolada, negativo, do *gap* médio de todos os estratos contrastivos reportado na Seção 5, de 0,09; são granularidades distintas, e a inversão de polo é o estrato que puxa a fragilidade ao extremo.) O conjunto será ainda depurado e ampliado, com os pares limítrofes reescritos para isolar legitimidade ativa de passiva, em versão futura.

Verificação por raciocínio. O experimento da Seção 9 usa esses mesmos pares e três modelos de uma única família; suas contagens individuais estão sujeitas ao n pequeno. O padrão central — domínio da formulação sobre a capacidade e recuperação dos recíprocos — é robusto, inclusive ao subconjunto limpo acima; as diferenças de poucos pares entre modelos não o são, e não são reivindicadas.

Dependência entre controle e contrastivos. O pareamento lexical do controle foi obtido, em três casos, reaproveitando como âncora uma das frases de um par contrastivo. Isso torna o Jaccard equiparado (0,79 contra 0,75) um cuidado real, mas viola a independência entre os grupos que o *bootstrap* pressupõe ao reamostrá-los separadamente; o intervalo de confiança do *gap* pareado é, por isso, mais estreito que o verdadeiro. A direção do sinal não muda, mas a precisão reportada é otimista, e um *bootstrap* pareado por âncora é o refinamento adequado.

Operacionalização do critério de acerto na verificação por raciocínio. As respostas livres dos modelos (Seção 9) foram convertidas em verdadeiro/falso por um *parser* de palavra-chave. Para um experimento cuja tese é que a formulação da pergunta decide o resultado, o critério de acerto deveria ser tão controlado quanto a pergunta; parte dos poucos erros decorreu de o modelo ler “papel” como função sintática, ambiguidade que o *parser* não resolve. O protocolo de *parsing* está no material de replicação, mas dupla anotação cega de uma amostra é o passo que faltaria para isolar a codificação do anotador.

Família única, língua única, ausência de baseline humano. Três limites de generalização que as ressalvas acima não nomeiam. O experimento de raciocínio usa modelos de uma só família, que compartilham dados e alinhamento, de modo que “a pergunta importa mais que o modelo” está demonstrada *dentro* de uma família e não entre fornecedores. Não há *baseline* humano em nenhuma camada: a afirmação de que o operador lê o cosseno de 0,99 como certeza é plausível e ancorada nos casos documentados, mas não medida, e onde não há medida do operador o texto deve ser lido no condicional. E os pares são frases isoladas, ao passo que a tese prática diz respeito a documentos longos em *pipelines* RAG, onde a diluição dos *tokens* de polo tende a agravar o efeito — o que é hipótese coerente, não resultado medido.

Nenhuma dessas limitações enfraquece a tese central, que diz respeito à *interpretação* dos escores de similaridade e foi confirmada em todos os modelos medidos. Elas delimitam a *generalização* da evidência, e o caminho para ampliá-la está especificado e instrumentado.

12 Conclusão

A tese é esta. O operador do Direito não precisa abordar a operação de IA pela perspectiva linguística porque ela é elegante, mas porque o objeto que opera é, na sua natureza mais profunda, um artefato linguístico e geométrico, e as falhas que ele produz têm a forma da representação distribucional do significado em um espaço vetorial enviesado. Este artigo tornou uma dessas falhas mensurável em português e mostrou algo que a intuição corrente inverte: o modelo de busca mais avançado não é mais seguro contra o erro de polaridade — é mais perigoso, porque o esconde melhor. A inversão de polo resiste a quatro gerações de modelos e a uma arquitetura de inferência; o aprendizado contrastivo do modelo de fronteira não a removeu, apenas a deslocou para um regime anisotrópico onde um cosseno de 0,99 disfarça uma discriminação de cinco milésimos. O operador que lê esse número como certeza comete o erro exato que a competência jurídica não o ensina a ver.

A competência jurídica diz ao operador se um precedente é aplicável. Não lhe diz se a máquina o está recuperando porque o sustenta ou porque o contradiz, nem com que margem, nem se o escore de similaridade que ele exibe é discriminação real ou artefato da geometria do espaço. Para responder a essas perguntas, que decidem se a IA será instrumento ou armadilha, é preciso uma alfabetização que a formação jurídica tradicional não fornece e que nenhum manual de atalhos substitui. É preciso entender a linguagem da máquina — e a geometria em que ela vive.

Disponibilidade de material. O conjunto de pares mínimos e os scripts de medição (cosseno, normalização por anisotropia, *cross-encoder* e recuperação) são reproduzíveis com **sentence-transformers** em CPU. Os resultados do modelo de fronteira foram obtidos com **multilingual-e5-large**.

Declaração sobre uso de IA. A redação foi assistida por ferramentas de IA sob revisão integral do autor. Os experimentos, dados e interpretação são de responsabilidade do autor.

Referências

- [1] DAHL, M.; MAGESH, V.; SUZGUN, M.; HO, D. E. *Large Legal Fictions: Profiling Legal Hallucinations in Large Language Models*. Journal of Legal Analysis, v. 16, n. 1, p. 64–93, 2024. <https://doi.org/10.1093/jla/laae003>.
- [2] ETHAYARAJH, K. *How Contextual are Contextualized Word Representations? Comparing the Geometry of BERT, ELMo, and GPT-2 Embeddings*. In: Proceedings of EMNLP-IJCNLP, 2019, p. 55–65. <https://doi.org/10.18653/v1/D19-1006>.
- [3] HÄMMERL, K.; LIBOVICKÝ, J.; FRASER, A. *Exploring Anisotropy and Outliers in Multilingual Language Models for Cross-Lingual Semantic Sentence Similarity*. In: Findings of ACL, 2023. <https://doi.org/10.18653/v1/2023.findings-acl.439>.
- [4] HARRIS, Z. S. *Distributional Structure*. Word, v. 10, n. 2–3, p. 146–162, 1954. <https://doi.org/10.1080/00437956.1954.11659520>.
- [5] LIN, Y.-T.; CHEN, Y.-N. *HEROS: A Diagnostic Probe of Sentence Encoders via Minimal Pairs (HEROS)*. Preprint, 2023. <https://arxiv.org/abs/2306.05083>.
- [6] MAGESH, V.; SURANI, F.; DAHL, M.; SUZGUN, M.; MANNING, C. D.; HO, D. E. *Hallucination-Free? Assessing the Reliability of Leading AI Legal Research Tools*. Journal of Empirical Legal Studies, 2025. <https://doi.org/10.1111/jels.12413>.
- [7] ESTADOS UNIDOS. United States District Court for the Southern District of New York. *Mata v. Avianca, Inc.*, No. 22-cv-1461 (PKC). Opinion and Order on Sanctions, 22 jun. 2023.
- [8] REIMERS, N.; GUREVYCH, I. *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks*. In: Proceedings of EMNLP-IJCNLP, 2019, p. 3982–3992. <https://doi.org/10.18653/v1/D19-1410>.