

A insuficiência da competência jurídica tradicional para a operação de modelos de linguagem: uma leitura linguística do erro, com evidência empírica em português

Pedro Borges Mourão

Promotor de Justiça, Ministério Público do Estado do Rio de Janeiro (MPRJ)., Pesquisador na interseção entre Direito, inteligência artificial e forense digital., pedro@example.org

27 de junho de 2026

Resumo

Circula entre operadores do Direito a suposição de que dominar uma ferramenta de inteligência artificial é uma questão de aprender comandos, à maneira de quem memoriza atalhos de um editor de texto. Este artigo argumenta que essa suposição é falsa e que seu custo não é a ineficiência, mas a fabricação de jurisprudência inexistente assinada pelo próprio operador. A tese é específica: a competência jurídica tradicional não transfere para a operação de um modelo de linguagem, porque o objeto operado não é um banco de dados de normas nem um buscador sofisticado, e sim um sistema que manipula distribuições estatísticas de linguagem. Suas falhas mais perigosas para o Direito — insensibilidade à negação, recuperação indistinta de aliados e adversários, sicofância e fabricação de citações — têm a forma da representação distribucional do significado, hipótese formulada por Harris em 1954. Para sustentar empiricamente essa leitura, construímos um conjunto de 23 pares mínimos forenses em português e medimos a similaridade de cosseno produzida por três modelos abertos de *sentence embedding* amplamente usados em produção. O resultado confirma e refina a tese: pares que invertem a consequência normativa recebem cosseno alto e quase indistinguível do atribuído a paráfrases legítimas (*gap* médio entre $-0,05$ e $0,15$), com a falha mais severa não na negação adverbial, mas na *inversão de polo* processual (autor $\leftrightarrow$ réu), onde o cosseno alcança $0,95$. Um *cross-encoder* treinado em inferência de linguagem natural, que processa o par conjuntamente, recupera a distinção perdida (detecta contradição em 19 de 20 pares contrastivos), demonstrando que a vulnerabilidade é arquitetural e mitigável a custo, não um defeito acidental. Todo o material é reproduzível. Conclui-se que a revisão humana responsável de saídas de IA exige uma alfabetização linguística que a formação jurídica não fornece e que nenhum manual de prompts substitui.

Palavras-chave: inteligência artificial jurídica; modelos de linguagem; hipótese distribucional; *embeddings*; insensibilidade à negação; recuperação aumentada; prova digital.

1 Introdução: uma suposição confortável e cara

Há uma suposição confortável circulando nos escritórios e órgãos públicos que operam a justiça no Brasil: a de que dominar uma ferramenta de inteligência artificial é uma questão de aprender comandos, como quem aprende os atalhos de um editor de texto. Descobre-se o botão certo, memorizam-se algumas fórmulas de prompt e, pronto, está-se operando. Essa suposição é falsa, e o custo de mantê-la não é a ineficiência. É a fabricação de jurisprudência inexistente assinada com o nome do operador.

O argumento deste texto é específico. Não se defende que advogados aprendam técnica de prompt. Defende-se algo anterior e mais incômodo: que a competência jurídica tradicional, aquela construída em anos de leitura de doutrina e prática forense, não transfere para a operação de um modelo de linguagem. Ela não transfere porque o objeto com que o operador lida não é um banco de dados de normas, nem um colega júnior apressado, nem um buscador sofisticado. É um sistema que manipula distribuições estatísticas de linguagem e que, por isso, falha de modos que só fazem sentido quando se entende como a linguagem foi representada matematicamente dentro dele. Quem não entende isso não está operando a ferramenta. Está sendo operado por ela.

A contribuição deste artigo é dupla. Primeiro, ele reconstrói o porquê dessas falhas a partir de sua origem linguística, e não de uma falha de engenharia. Segundo — e é o que distingue este texto de um ensaio de posicionamento —, ele oferece evidência empírica direta, reproduzível e em língua portuguesa, de que o componente mais difundido da arquitetura de IA jurídica comercial, o *sentence embedding*, não distingue afirmação de negação, nem o polo ativo do passivo, quando isso mais importa.

2 O caso que expõe a natureza do problema

Comece-se por um experimento que qualquer pessoa pode reproduzir e que a literatura técnica vem documentando com consistência crescente [2]. Tomem-se duas frases que dizem o oposto uma da outra: “o réu compareceu à audiência” e “o réu não compareceu à audiência”. Para um operador do Direito, essas frases são antípodas. A presença ou ausência do réu muda o procedimento, dispara ou não a revelia (art. 344 do CPC), pode redesenhar o ônus da prova. A diferença entre elas é a diferença entre dois processos.

Submetam-se essas duas frases a um modelo de *embedding*, o componente que converte texto em vetores numéricos e que serve de base para busca semântica, sistemas de recuperação e boa parte da arquitetura de IA jurídica hoje comercializada. O modelo as considerará semelhantes. A similaridade de cosseno entre os dois vetores será alta quando deveria ser baixa. A Seção 3 mede exatamente isso e mostra que “alta” é o comportamento da regra, não da exceção.

Embora a engenharia tente mitigar o problema com métodos de treinamento como aprendizado contrastivo e *rerankers*, a arquitetura base do bi-encoder carrega essa vulnerabilidade em sua estrutura. O operador que terceiriza essa vigilância para a próxima atualização do sistema caminha no escuro.

O que precisa ser conhecido é que, mitigada ou não, há uma consequência estrutural de como esses modelos aprendem o que as palavras significam. A causa é explícita: a insensibilidade à negação deriva da hipótese distribucional formulada por Zellig Harris em 1954, segundo a qual o significado de uma palavra é capturado pelos contextos em que ela aparece [3]. Modelos de *embedding* aprendem que “compareceu” e “não compareceu” significam coisas parecidas porque aparecem em contextos textuais quase idênticos, cercados das mesmas palavras, na mesma sintaxe. O advérbio de negação é, para a estatística distribucional, uma perturbação mínima no contexto. Para o Direito, é a inversão completa do sentido. A máquina otimiza para a regularidade da superfície linguística; o jurista opera no nível da consequência normativa. São duas leituras incompatíveis do mesmo texto, e o operador que ignora a primeira interpreta os resultados pela segunda, atribuindo ao sistema uma compreensão que ele não tem.

Isto não é especulação nem opinião de um crítico de IA. É o comportamento esperado de qualquer modelo construído sobre a premissa distribucional, e é por isso que pares mínimos de negação retornam similaridade de cosseno alta apesar de afirmarem o contrário um do outro. O efeito é reproduzível por qualquer interessado: não é preciso confiar em ninguém para constatá-lo. As seções seguintes o constatarem.

3 Método

3.1 Construção do conjunto de pares mínimos forenses

Um *par mínimo* é um par de sentenças que compartilha quase toda a superfície lexical e difere em um ponto que inverte o sentido. Em linguística, pares mínimos isolam o efeito de uma única variável. Aqui, a variável é sempre uma perturbação de baixa massa lexical que carrega alta carga normativa. Construímos 23 pares em português jurídico, estratificados pelo *mecanismo* de inversão, porque a hipótese distribucional prevê sensibilidade diferente conforme o operador semântico (Tabela 1):

Estrato	<i>n</i>	Exemplo (frase A / frase B)
Negação adverbial	6	<i>O réu compareceu. . . / O réu não compareceu. . .</i>
Antonímia de núcleo	6	<i>. . . foi deferido / . . . foi indeferido</i>
Inversão de polo	4	<i>O autor deve indenizar o réu / O réu deve indenizar o autor</i>
Quantificador/modal	4	<i>Todos os requisitos. . . / Nenhum dos requisitos. . .</i>
Controle (paráfrase)	3	<i>. . . não compareceu / . . . deixou de comparecer</i>

Tabela 1: Estratos do conjunto de pares mínimos. Os três pares de *controle* são paráfrases legítimas: ali, cosseno alto é a resposta *correta*. Sua função é provar que cosseno alto nos pares contrastivos é um erro de discriminação, e não saturação geral do modelo.

O estrato de controle é a peça metodológica central. Sem ele, um cosseno alto entre “compareceu” e “não compareceu” poderia ser atribuído a um modelo que simplesmente satura toda comparação perto de 1,0. Com ele, é possível separar duas coisas distintas: a similaridade que o modelo *deve* reconhecer (entre paráfrases) e a diferença que o modelo *deveria* reconhecer (entre sentenças de sentido oposto). A falha que este artigo documenta é a ausência de separação entre as duas.

3.2 Modelos e medida

Medimos três modelos abertos de *sentence embedding* multilíngues, escolhidos por cobrirem famílias, tamanhos e estratégias de treino distintas, e por estarem entre os mais utilizados em pipelines de produção: `paraphrase-multilingual-MiniLM-L12-v2`, `paraphrase-multilingual-mpnet-base-v2` e `distiluse-base-multilingual-cased-v2`, todos da biblioteca `sentence-transformers` [6]. Para cada par, cada sentença é codificada em um vetor normalizado e calcula-se a similaridade de cosseno

$$\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}.$$

A execução é determinística e roda em CPU, sem custo. O código, o conjunto de dados e os vetores estão disponíveis para replicação integral.

3.3 Contraprova arquitetural: o *cross-encoder* NLI

Para testar a afirmação de que a vulnerabilidade é arquitetural — e não uma propriedade inevitável de todo modelo de linguagem —, submetemos os mesmos 23 pares a um *cross-encoder* treinado em inferência de linguagem natural (`nli-deberta-v3-base`), que classifica cada par como *contradição*, *implicação* ou *neutro*. A diferença é arquitetural e decisiva: o bi-encoder codifica cada sentença *isoladamente* e só depois as compara, ao passo que o *cross-encoder* processa as duas sentenças *conjuntamente*, com atenção cruzada entre elas. Se a distinção afirmação/negação é recuperável quando o modelo lê o par junto, isso prova que a informação está no texto e que é a *compressão em um vetor único* que a descarta.

4 Resultados

4.1 O bi-encoder não distingue inversão de sentido de paráfrase

A Figura 1 mostra o cosseno médio por modelo e estrato. Três fatos se destacam. Primeiro, os pares contrastivos — que afirmam o oposto um do outro — recebem cosseno consistentemente alto, frequentemente acima de 0,7 e em vários casos acima de 0,9. Segundo, e contra a intuição mais difundida, a negação adverbial explícita (“não”) é o estrato *menos* problemático: a presença de um marcador lexical de negação dá ao modelo algo a que se agarrar. O estrato mais perigoso é a **inversão de polo**, em que trocar “autor” por “réu” — dois tokens de altíssima frequência em contextos idênticos — produz cosseno de 0,92 a 0,95. Para a estatística distribucional, a troca é quase invisível; para o processo, ela inverte quem paga, quem deve, quem tem razão. Terceiro, o modelo **distiluse** satura todos os estratos perto de 0,9, inclusive os contrastivos, o que o torna o pior dos três para qualquer tarefa que dependa de distinguir sentido oposto.




Figura 1: Similaridade de cosseno média por modelo e mecanismo de inversão. A coluna tracejada (controle) é o único lugar onde cosseno alto é correto. Que as demais colunas estejam tão escuras quanto ela é precisamente a falha.

A Figura 2 torna a falha explícita ao confrontar, para cada modelo, o cosseno médio dos pares contrastivos (que *deveria* ser baixo) com o dos controles de paráfrase (que *deveria* ser alto). As barras estão quase à mesma altura. O *gap* entre o que o modelo deveria separar fica entre $-0,05$ (distiluse, que inverte a ordem esperada) e $0,15$ (mpnet, o melhor dos três, ainda assim insuficiente). Em termos operacionais: um sistema de recuperação construído sobre qualquer um desses *embeddings* trata uma sentença e sua negação como praticamente o mesmo conteúdo, e não consegue separar essa confusão de uma reformulação sinônima legítima.




Figura 2: Pares contrastivos *versus* controles de paráfrase. Barras próximas indicam falha: o modelo não separa inversão de sentido de reformulação sinônima.

4.2 A distinção existe no texto: o *cross-encoder* a recupera

A Figura 3 mostra o resultado do *cross-encoder* NLI. A probabilidade atribuída à classe *contradição* separa nitidamente os dois grupos: média de 0,95 para os pares contrastivos contra 0,31 para os controles. Dos 20 pares de sentido oposto, 19 foram corretamente classificados como contradição. A informação que distingue afirmação de negação, portanto, estava no texto o tempo todo. O que a descarta é a etapa de compressão do bi-encoder, que projeta a sentença inteira em um único vetor otimizado para proximidade distribucional. Esta é a evidência empírica direta de que a vulnerabilidade é arquitetural e mitigável — a um custo computacional que muitos sistemas em produção não pagam, porque comparar todos os pares com atenção cruzada é ordens de magnitude mais caro do que indexar vetores.




Figura 3: Distribuição de $P(\text{contradição})$ do *cross-encoder* NLI. A arquitetura que lê o par conjuntamente recupera a distinção que o bi-encoder perde.

4.3 Tabela completa

A Tabela 2 reporta as estatísticas por modelo e estrato, para verificação. Reportamos média, desvio-padrão populacional, mínimo e máximo. Nenhum valor foi selecionado ou suprimido; os 23 pares de cada modelo entram na agregação.

Modelo	Estrato	μ	σ	min	max
MiniLM-multilingual	negacao_adverbial	0.550	0.091	0.419	0.663
MiniLM-multilingual	antonimia_nucleo	0.724	0.194	0.480	0.955
MiniLM-multilingual	inversao_polo	0.935	0.050	0.865	0.989
MiniLM-multilingual	quant_modal	0.693	0.156	0.502	0.919
MiniLM-multilingual	controle_parafrase	0.797	0.029	0.764	0.834
mpnet-multilingual	negacao_adverbial	0.490	0.058	0.410	0.554
mpnet-multilingual	antonimia_nucleo	0.769	0.160	0.551	0.977
mpnet-multilingual	inversao_polo	0.919	0.089	0.772	0.990
mpnet-multilingual	quant_modal	0.562	0.148	0.329	0.724
mpnet-multilingual	controle_parafrase	0.828	0.042	0.795	0.887
distiluse-multilingual	negacao_adverbial	0.844	0.042	0.772	0.886
distiluse-multilingual	antonimia_nucleo	0.925	0.050	0.861	0.990
distiluse-multilingual	inversao_polo	0.947	0.075	0.818	0.999
distiluse-multilingual	quant_modal	0.901	0.050	0.816	0.945
distiluse-multilingual	controle_parafrase	0.851	0.072	0.750	0.913

Tabela 2: Similaridade de cosseno agregada por modelo e estrato (n pares por célula conforme a Tabela 1).

5 Por que isso é um problema linguístico, e não técnico

Aqui está o ponto que separa este artigo dos manuais de prompt. O operador poderia reagir à seção anterior dizendo: “ótimo, então preciso de um engenheiro que conserte o modelo de negação”. Reação errada. O problema não se resolve no nível da engenharia porque ele não nasce de um erro de engenharia. Nasce da escolha de representar significado por proximidade distribucional, escolha que é simultaneamente a fonte de todo o poder desses modelos e a fonte de suas falhas mais perigosas para o Direito. O *cross-encoder* da Seção 4 não “conserta” o bi-encoder; ele substitui o paradigma de representação por outro, mais caro, e o faz apenas para o par que lhe é apresentado, não para um corpus inteiro indexado.

A menos que o sistema utilize arquiteturas sofisticadas e caras de reordenação neural, que muitas ferramentas no mercado não têm, quem busca jurisprudência favorável num corpus vetorizado recupera, lado a lado e indistintos, os precedentes que sustentam sua tese e os que a demolem, com escores de relevância que não distinguem aliado de adversário. Isto não é apenas uma leitura particular: o próprio estudo de Stanford sobre ferramentas jurídicas observa que documentos apenas textualmente parecidos são recuperados como relevantes e acabam distraindo o sistema, degradando a resposta [4].

A negação é o exemplo mais limpo do modelo lidando com o texto. Mas a arquitetura tem outras camadas que agravam o problema. Há a sicofância, que a pesquisa de IA jurídica isolou como um dos modos de erro mais perigosos. O modelo foi desenhado, por um processo de alinhamento humano, para ser prestativo e agradável, não para buscar a verdade jurídica. Ele espelha a estrutura argumentativa que lhe é entregue.

Nenhuma dessas falhas é visível para quem opera o sistema como se fosse um buscador ou um assistente. Todas são previsíveis para quem entende que está lidando com um modelo estatístico de linguagem. A diferença entre o operador competente e o operador exposto não é a quantidade de prompts que ele conhece. É a presença ou ausência de um modelo mental correto do que a máquina está fazendo com a linguagem.

6 A escala do dano já documentada

Quem considera isto uma preocupação meramente teórica não acompanhou os números. Um estudo da Stanford RegLab sobre alucinação jurídica em modelos de propósito geral encontrou taxas entre 58% e 82% nas respostas a consultas jurídicas, e a constatação de que o desempenho em doutrina substantiva mal supera o chute aleatório [1]. Um segundo estudo, avaliando as

ferramentas jurídicas dedicadas que prometem ancorar as respostas em fontes reais por recuperação aumentada, ainda registrou 17% de alucinação no Lexis+ AI e 33% no Westlaw, com taxa mais alta no GPT-4 sem essa arquitetura [4]. Recuperação aumentada reduz o problema; não o elimina. E a Seção 4 expõe um dos mecanismos pelos quais a recuperação falha na origem: se o passo de *embedding* não distingue uma tese de sua negação, a recuperação que alimenta o gerador já entrega material contaminado.

E há o caso fundador, que todo operador deveria conhecer não como anedota, mas como diagnóstico. Em *Mata v. Avianca*, dois advogados protocolaram nos Estados Unidos uma peça com seis citações geradas por IA. Nenhum dos casos existia: nomes falsos, números de processo falsos, fundamentação falsa. O detalhe que importa para este argumento é o seguinte: quando um dos advogados pediu ao modelo que confirmasse se as citações eram reais, ele confirmou, afirmando que poderiam ser encontradas nas bases jurídicas conhecidas [5]. O sistema não mentiu por malícia. Ele gerou a continuação estatisticamente mais provável para a pergunta “essas citações são reais?”, e a continuação mais provável, dado o contexto, era a confirmação. O operador interpretou isso como verificação. Era espelhamento. A sanção, registre-se, não veio da fabricação inicial, mas da insistência em não retratar depois que a inexistência foi apontada pela parte contrária e pelo juízo.

A lição não é “a IA erra, tome cuidado”. Essa lição é inútil porque não diz onde nem por que ela erra. A lição é que os erros têm uma gramática. Eles seguem a lógica da representação distribucional da linguagem, e quem conhece essa gramática sabe antecipar onde o sistema vai falhar: na negação, no antagonismo de proximidade, na inversão de polo, na premissa falsa embutida, na citação de fonte que precisa existir mas pode não existir. O operador linguisticamente alfabetizado não confia menos na ferramenta de modo difuso. Ele desconfia de modo cirúrgico, nos pontos exatos onde a arquitetura prevê a falha. E é exatamente isto que constitui uma revisão humana responsável e eficiente de saída de IA.

7 O que muda quando o operador entende a linguagem da máquina

A perspectiva linguística não é um adorno acadêmico que se acrescenta à competência técnica. Ela reorganiza a prática inteira. Três deslocamentos concretos decorrem dela.

O primeiro é na verificação. Quem entende que o modelo gera a continuação mais plausível, e não a mais verdadeira, para de pedir ao próprio modelo que confirme os fatos que ele produziu, porque essa confirmação é mais texto plausível, não checagem. A verificação migra obrigatoriamente para fora do sistema, para a fonte primária, e isso deixa de ser uma recomendação genérica de prudência para virar uma consequência necessária da arquitetura. O fundamento normativo de uma peça assistida por IA precisa ser conferido na fonte não porque é boa prática, mas porque, por hipótese, o sistema que o sugeriu pode não ter acesso real à íntegra da fonte ou, mesmo fornecida, não a “leu” corretamente.

O segundo é na formulação da entrada. Compreender o espelho reativo muda como se interroga o modelo. Em vez de entregar a tese pronta e pedir fundamentação, o que convida o sistema a espelhar e a fabricar suporte, o operador competente formula a consulta de modo a forçar o contraditório: pede a antítese, solicita as objeções mais fortes à própria posição, estrutura a entrada para que a máquina trabalhe contra a premissa e não a favor dela. Isto não é truque de prompt. É a aplicação direta de um entendimento sobre como o modelo processa a estrutura argumentativa que recebe.

O terceiro é na arquitetura dos sistemas que o próprio Direito está construindo. Quem vai projetar ou contratar um pipeline de recuperação jurídica precisa saber que vetorizar peças sem tratar a proximidade antagônica produz um sistema que tende a recuperar adversários como se fossem aliados — e a evidência da Seção 4 quantifica esse risco. Precisa saber que a insensibilidade à negação e à inversão de polo pode comprometer qualquer busca que dependa de distinguir o

que um precedente afirma do que ele nega, ou a favor de quem decide. As decisões de arquitetura — o tipo de *embedding*, a estratégia de fragmentação do texto, o uso ou não de um *reranker* de atenção cruzada, o tratamento de pares dialéticos — são decisões linguísticas antes de serem decisões de engenharia, e o jurista que não as entende terceiriza para o fornecedor escolhas que determinam se o sistema vai sustentar ou sabotar o trabalho.

8 Limitações e ameaças à validade

A honestidade metodológica exige delimitar o alcance das medições. Primeiro, o conjunto de 23 pares é pequeno e foi construído por um único autor com expertise de domínio; ele ilustra mecanismos, não estabelece distribuições populacionais. Trabalho futuro deve ampliá-lo e submetê-lo a anotação independente. Segundo, medimos três modelos abertos multilíngues; modelos proprietários de *embedding* mais recentes, alguns treinados com sinal de NLI, podem atenuar o efeito, e a comparação fica registrada como extensão natural. O ponto do artigo, contudo, não é que *todo embedding* falhe sempre, e sim que a falha é uma propriedade estrutural do paradigma distribucional que persiste, em grau variável, em modelos amplamente usados, e que o operador não pode pressupor sua ausência. Terceiro, a similaridade de cosseno é uma medida intrínseca; o impacto em uma tarefa de recuperação ponta a ponta depende de limiar, indexação e *reranking*, o que o estudo de Stanford já documenta no nível do produto [4]. Nada disso enfraquece a tese central: enfraqueceria apenas uma versão caricata dela que afirmasse impossibilidade técnica, e não é essa a afirmação.

9 Conclusão

A tese, então, é esta. O operador do Direito não precisa abordar a operação de IA pela perspectiva linguística porque a linguística é elegante ou porque confere um verniz interdisciplinar ao currículo. Precisa porque o objeto que ele opera é, na sua natureza mais profunda, um artefato linguístico estatístico, e as falhas que esse artefato produz — as que arruinam peças, geram sanções e fabricam jurisprudência — são falhas linguísticas. Elas têm a forma da representação distribucional do significado. São previsíveis para quem conhece essa forma e invisíveis para quem não conhece. Este artigo tornou uma dessas falhas mensurável em português: a confusão entre uma sentença e sua negação, e entre o polo ativo e o passivo, no componente que sustenta a recuperação semântica.

A competência jurídica diz ao operador se um precedente é aplicável. Não lhe diz se o precedente existe, nem se a máquina o está recuperando porque o sustenta ou porque o contradiz, nem se a confirmação que ele acabou de receber é verificação ou eco. Para responder a essas perguntas, que são as perguntas que decidem se a IA será instrumento ou armadilha, é preciso uma alfabetização que a formação jurídica tradicional não fornece e que nenhum manual de atalhos substitui. É preciso entender a linguagem da máquina. Não a sintaxe dos comandos, mas a lógica de como ela representa, e deforma, o significado.

Disponibilidade de material. O conjunto de pares mínimos, o código de medição (bi-encoder e *cross-encoder*) e os resultados brutos que sustentam todas as figuras e tabelas são reproduzíveis com a biblioteca `sentence-transformers` em CPU, sem dependência de serviços proprietários.

Declaração sobre uso de IA. A redação foi assistida por ferramentas de IA sob revisão integral do autor. Os experimentos, dados e a interpretação são de responsabilidade do autor. Esta declaração atende às diretrizes de transparência sobre uso de modelos de linguagem na preparação de manuscritos.

Referências

- [1] DAHL, M.; MAGESH, V.; SUZGUN, M.; HO, D. E. *Large Legal Fictions: Profiling Legal Hallucinations in Large Language Models*. Journal of Legal Analysis, v. 16, n. 1, p. 64–93, 2024. <https://doi.org/10.1093/jla/laae003>. Preprint: <https://arxiv.org/abs/2401.01301>.
- [2] ETTINGER, A. *What BERT Is Not: Lessons from a New Suite of Psycholinguistic Diagnostics for Language Models*. Transactions of the Association for Computational Linguistics, v. 8, p. 34–48, 2020. https://doi.org/10.1162/tac1_a_00298.
- [3] HARRIS, Z. S. *Distributional Structure*. Word, v. 10, n. 2–3, p. 146–162, 1954. <https://doi.org/10.1080/00437956.1954.11659520>.
- [4] MAGESH, V.; SURANI, F.; DAHL, M.; SUZGUN, M.; MANNING, C. D.; HO, D. E. *Hallucination-Free? Assessing the Reliability of Leading AI Legal Research Tools*. Journal of Empirical Legal Studies, 2025. <https://doi.org/10.1111/jels.12413>. Preprint: <https://arxiv.org/abs/2405.20362>.
- [5] ESTADOS UNIDOS. United States District Court for the Southern District of New York. *Mata v. Avianca, Inc.*, No. 22-cv-1461 (PKC). Opinion and Order on Sanctions, 22 jun. 2023. <https://www.law.berkeley.edu/wp-content/uploads/archive/2025/12/Mata-v-Avianca-Inc.pdf>.
- [6] REIMERS, N.; GUREVYCH, I. *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks*. In: Proceedings of EMNLP-IJCNLP, 2019, p. 3982–3992. <https://doi.org/10.18653/v1/D19-1410>.