

A insuficiência da competência jurídica tradicional para a operação de modelos de linguagem: uma leitura linguística do erro, com evidência empírica em português

Pedro Borges Mourão

Promotor de Justiça, Ministério Público do Estado do Rio de Janeiro (MPRJ), Pesquisador na interseção entre Direito, inteligência artificial e forense digital., pedro@example.org

27 de junho de 2026

Resumo

Circula entre operadores do Direito a suposição de que dominar uma ferramenta de inteligência artificial é uma questão de aprender comandos, à maneira de quem memoriza atalhos de um editor de texto. Este artigo argumenta que essa suposição é falsa e que seu custo não é a ineficiência, mas a fabricação de jurisprudência inexistente assinada pelo próprio operador. A tese é específica: a competência jurídica tradicional não transfere para a operação de um modelo de linguagem, porque o objeto operado não é um banco de dados de normas nem um buscador sofisticado, e sim um sistema que manipula distribuições estatísticas de linguagem. Para examinar empiricamente uma de suas falhas mais difundidas — a representação deficiente da polaridade —, construímos um conjunto de 40 pares mínimos forenses em português e medimos a similaridade de cosseno produzida por três modelos abertos de *sentence embedding* amplamente usados em produção. Os resultados sustentam uma conclusão mais matizada e mais sólida do que a intuição corrente. Em uma comparação lexicalmente pareada, dois dos três modelos *separam* paráfrase de inversão de sentido na média (*gap* de 0,12 e 0,15, IC95 excluindo zero), mas o terceiro não separa (*gap* de $-0,01$, IC95 incluindo zero), e o valor absoluto da similaridade entre uma sentença e sua negação permanece alto (0,79 a 0,93). A falha mais severa não está na negação adverbial — a presença do advérbio “não” dá ao modelo um marcador a que se agarrar —, mas na **inversão de polo processual** (autor $\leftrightarrow$ réu), onde o cosseno alcança 0,96 a 0,97 ($n = 16$) e que resiste inclusive a um *cross-encoder* de inferência (detectada como contradição em apenas 9 de 16 casos). Quando se testa o efeito em uma tarefa de recuperação realista, com *query* temática, os modelos rankeiam a sentença correta acima da oposta na maioria dos casos (80% a 95%), porém por margens tênues cujos mínimos tocam o zero. A conclusão, portanto, não é que esses sistemas recuperem adversários como aliados de forma determinística, e sim que o sinal de polaridade é estruturalmente frágil e degrada sob condições realistas — fragilidade previsível para quem entende a representação distribucional e invisível para quem a ignora. Todo o material é reproduzível.

Palavras-chave: inteligência artificial jurídica; modelos de linguagem; hipótese distribucional; *embeddings*; polaridade; recuperação de informação; prova digital.

1 Introdução: uma suposição confortável e cara

Há uma suposição confortável circulando nos escritórios e órgãos públicos que operam a justiça no Brasil: a de que dominar uma ferramenta de inteligência artificial é uma questão de aprender comandos, como quem aprende os atalhos de um editor de texto. Descobre-se o botão certo,

memorizam-se algumas fórmulas de prompt e, pronto, está-se operando. Essa suposição é falsa, e o custo de mantê-la não é a ineficiência. É a fabricação de jurisprudência inexistente assinada com o nome do operador.

O argumento deste texto é específico. Não se defende que advogados aprendam técnica de prompt. Defende-se algo anterior e mais incômodo: que a competência jurídica tradicional, aquela construída em anos de leitura de doutrina e prática forense, não transfere para a operação de um modelo de linguagem. Ela não transfere porque o objeto com que o operador lida não é um banco de dados de normas, nem um colega júnior apressado, nem um buscador sofisticado. É um sistema que manipula distribuições estatísticas de linguagem e que, por isso, falha de modos que só fazem sentido quando se entende como a linguagem foi representada matematicamente dentro dele. Quem não entende isso não está operando a ferramenta. Está sendo operado por ela.

A contribuição deste artigo é dupla. Primeiro, ele reconstrói o porquê dessas falhas a partir de sua origem linguística, e não de uma falha de engenharia. Segundo — e é o que distingue este texto de um ensaio de posicionamento —, ele oferece evidência empírica direta, reproduzível e em língua portuguesa sobre o comportamento do componente mais difundido da arquitetura de IA jurídica comercial, o *sentence embedding*, diante da polaridade. Importa, desde já, ser preciso sobre o que a evidência mostra e o que não mostra: ela não estabelece que esses sistemas falhem sempre, e sim que tratam a polaridade — afirmação *versus* negação, polo ativo *versus* passivo — como um sinal estruturalmente fraco, cuja preservação não pode ser pressuposta pelo operador.

2 O caso que expõe a natureza do problema

Comece-se por um experimento que qualquer pessoa pode reproduzir e que a literatura técnica vem documentando com consistência crescente [2]. Tomem-se duas frases que dizem o oposto uma da outra: “o réu compareceu à audiência” e “o réu não compareceu à audiência”. Para um operador do Direito, essas frases são antípodas. A presença ou ausência do réu muda o procedimento, dispara ou não a revelia (art. 344 do CPC), pode redesenhar o ônus da prova. A diferença entre elas é a diferença entre dois processos.

Submetam-se essas duas frases a um modelo de *embedding*, o componente que converte texto em vetores numéricos e que serve de base para busca semântica, sistemas de recuperação e boa parte da arquitetura de IA jurídica hoje comercializada. A similaridade que o modelo atribui ao par é alta. A questão empírica, que a Seção 4 responde com cuidado metodológico, é *quão* alta em comparação com uma paráfrase legítima, e se essa diferença sobrevive quando se isola a variável correta.

A causa do fenômeno é conhecida e precede qualquer arquitetura específica: a representação distribucional do significado, formulada por Zellig Harris em 1954, segundo a qual o significado de uma palavra é capturado pelos contextos em que ela aparece [3]. Modelos de *embedding* aprendem que “compareceu” e “não compareceu” significam coisas parecidas porque aparecem em contextos textuais quase idênticos, cercados das mesmas palavras, na mesma sintaxe. O advérbio de negação é, para a estatística distribucional, uma perturbação mínima no contexto. Para o Direito, é a inversão completa do sentido. A máquina otimiza para a regularidade da superfície linguística; o jurista opera no nível da consequência normativa. São duas leituras incompatíveis do mesmo texto, e o operador que ignora a primeira interpreta os resultados pela segunda, atribuindo ao sistema uma compreensão que ele não tem.

Embora a engenharia tente mitigar o problema com métodos de treinamento como aprendizado contrastivo e *rerankers*, a arquitetura base do bi-encoder — que comprime cada sentença em um único vetor antes de qualquer comparação — carrega essa tendência em sua estrutura. O operador que terceiriza essa vigilância para a próxima atualização do sistema caminha no escuro. As seções seguintes medem o tamanho real do problema, e o fazem sem exagerá-lo: parte do que se atribui ingenuamente a uma “falha de compreensão” é, na verdade, mera sobreposição lexical,

e separar uma coisa da outra é a primeira exigência metodológica séria.

3 Método

3.1 Pares mínimos e o problema do controle

Um *par mínimo* é um par de sentenças que compartilha quase toda a superfície lexical e difere em um ponto que inverte o sentido. Em linguística, pares mínimos isolam o efeito de uma única variável. Construímos 40 pares em português jurídico, estratificados pelo *mecanismo* de inversão (Tabela 1), porque a hipótese distribucional prevê sensibilidade diferente conforme o operador semântico.

Estrato	<i>n</i>	Exemplo (frase A / frase B)
Negação adverbial	6	<i>O réu compareceu...</i> / <i>O réu não compareceu...</i>
Antonímia de núcleo	6	<i>...foi deferido</i> / <i>...foi indeferido</i>
Inversão de polo	16	<i>O autor deve indenizar o réu</i> / <i>O réu deve indenizar o autor</i>
Quantificador/modal	4	<i>Todos os requisitos...</i> / <i>Nenhum dos requisitos...</i>
Controle pareado	8	<i>...foi indeferido</i> / <i>...foi rejeitado</i>

Tabela 1: Estratos do conjunto. O estrato de *inversão de polo* foi deliberadamente ampliado para $n = 16$, por concentrar o efeito mais forte. Os oito pares de *controle* são paráfrases legítimas: ali, cosseno alto é a resposta *correta*.

O estrato de controle merece justificativa metodológica explícita, porque um controle mal construído invalidaria toda a comparação. A função do controle é permitir separar duas coisas distintas: a similaridade que o modelo *deve* reconhecer (entre paráfrases de mesmo sentido) e a diferença que o modelo *deveria* reconhecer (entre sentenças de sentido oposto). O risco é que pares contrastivos e pares de controle difiram não apenas na dimensão de interesse (preserva *versus* inverte o sentido), mas também na sobreposição lexical de superfície — e, nesse caso, qualquer diferença de cosseno seria confundida com o artefato lexical. Para evitá-lo, os pares de controle são **lexicalmente pareados** aos contrastivos: paráfrases que preservam o sentido trocando uma única palavra por um sinônimo (*indeferido* → *rejeitado*; *demanda* → *ação*), de modo que a sobreposição lexical, medida pelo índice de Jaccard, seja equivalente. Verificamos: a sobreposição média é de 0,79 para os contrastivos e 0,75 para o controle pareado. A comparação, assim, difere essencialmente apenas na variável de interesse.

3.2 Modelos e medida

Medimos três modelos abertos de *sentence embedding* multilíngues, escolhidos por cobrirem famílias, tamanhos e estratégias de treino distintas, e por estarem entre os mais utilizados em pipelines de produção: `paraphrase-multilingual-MiniLM-L12-v2`, `paraphrase-multilingual-mpnet-base-v2` e `distiluse-base-multilingual-cased-v2`, da biblioteca `sentence-transformers` [6]. Cada sentença é codificada em um vetor normalizado e calcula-se a similaridade de cosseno

$$\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}.$$

Toda comparação agregada acompanha intervalo de confiança de 95% obtido por *bootstrap* (5,000 reamostragens), porque os estratos são pequenos e afirmações sem medida de incerteza seriam inadequadas. A execução é determinística, roda em CPU, sem custo, e o material é reproduzível na íntegra.

3.3 Duas medições distintas: intrínseca e extrínseca

O ponto metodológico central deste artigo é a distinção, frequentemente ignorada, entre dois níveis de medição. A medição *intrínseca* pergunta qual o cosseno entre uma sentença e sua negação, isoladamente. A medição *extrínseca* pergunta se, em uma tarefa de recuperação, dada uma *query*, a sentença correta é rankeada acima de sua negação. As duas não são equivalentes: a recuperação decide por *ranking contra a query*, não por similaridade par-a-par. Um sistema pode atribuir cosseno alto entre A e $\neg A$ e ainda assim rankear A corretamente, se a *query* for mais próxima de A . Medir apenas o nível intrínseco e concluir sobre recuperação seria um erro inferencial. Por isso reportamos ambos.

3.4 Contraprova arquitetural: o *cross-encoder* NLI

Para testar se a deficiência é arquitetural — e não uma propriedade inevitável de todo modelo de linguagem —, submetemos os mesmos 40 pares a um *cross-encoder* treinado em inferência de linguagem natural (*nli-deberta-v3-base*), que classifica cada par como *contradição*, *implicação* ou *neutro*. A diferença é arquitetural: o bi-encoder codifica cada sentença *isoladamente*; o *cross-encoder* processa as duas *conjuntamente*, com atenção cruzada. Se a distinção é recuperável quando o modelo lê o par junto, isso indica que a informação está no texto e que é a compressão em vetor único que a estreita.

4 Resultados

4.1 Cosseno por estrato: a negação não é o pior caso

A Figura 1 mostra o cosseno médio por modelo e estrato. Contrariando a intuição mais difundida, a negação adverbial explícita (“não”) é o estrato *menos* problemático: a presença de um marcador lexical de negação dá ao modelo algo a que se agarrar, e o cosseno cai para a faixa de 0,49 a 0,84 conforme o modelo. O estrato mais severo é a **inversão de polo**, em que trocar “autor” por “réu” — dois *tokens* de altíssima frequência em contextos idênticos — produz cosseno de 0,96 a 0,97, com intervalo de confiança estreito sobre $n = 16$ (por exemplo, 0,958, IC95 [0,934, 0,978] no MiniLM). Para a estatística distribucional, a troca é quase invisível; para o processo, ela inverte quem paga, quem deve, quem tem razão.




Figura 1: Cosseno médio por modelo e mecanismo de inversão. A coluna tracejada (controle pareado) é o único lugar onde cosseno alto é correto. A inversão de polo é a coluna mais escura em todos os modelos.

4.2 Comparação lexicalmente pareada: dois modelos separam, um não

A Figura 2 confronta, para cada modelo, o cosseno médio dos pares contrastivos com o do controle lexicalmente pareado. Este é o teste que isola a variável de interesse, e seu resultado é heterogêneo, o que deve ser reportado com honestidade. Em MiniLM e mpnet há separação estatisticamente sustentada: o *gap* é de 0,12 (IC95 [0,03, 0,20]) e 0,15 (IC95 [0,06, 0,24]), ambos excluindo zero. Esses modelos distinguem, na média, inversão de sentido de paráfrase melhor do que a intuição sugere. Em distiluse não há separação: o *gap* é de $-0,01$ (IC95 $[-0,07, 0,05]$), incluindo zero — esse modelo trata uma sentença, sua negação e sua paráfrase como praticamente equivalentes.

Há, porém, um fato que a separação na média não apaga: o cosseno *absoluto* entre uma sentença e seu oposto permanece alto, entre 0,79 e 0,93. Em um corpus real, um escore dessa magnitude posiciona o documento de sentido contrário entre os candidatos mais bem ranqueados. A separação existe, mas opera sobre uma base de similaridade tão alta que sua margem de segurança é estreita — o que a Seção 4.3 confirma na tarefa-fim.




Figura 2: Pares contrastivos *versus* controle lexicalmente pareado (mesma sobreposição de Jaccard). MiniLM e mpnet separam (*gap* com IC95 acima de zero); distiluse não separa (IC95 incluindo zero).

4.3 Recuperação realista: o modelo distingue, por margem tênue

A medição que importa para a prática é a extrínseca. Construímos 20 cenários de recuperação em que a *query* é temática e expressa a intenção de uma polaridade sem copiar a sentença, e o corpus contém a sentença correta e sua oposta. A Figura 3 reporta a taxa de acerto de *ranking* e a margem de cosseno entre a sentença correta e a incorreta.

O resultado refuta a versão forte da tese e sustenta a versão correta. Os modelos *distinguem*: rankeiam a sentença correta acima da oposta em 95% (MiniLM, IC95 [0,85, 1,00]), 80% (mpnet, IC95 [0,60, 0,95]) e 95% (distiluse) dos casos. Não é, portanto, verdade que esses sistemas recuperem “adversários como aliados” de forma determinística. Mas as margens que sustentam esses acertos são tênues: a margem mínima toca o zero em MiniLM ($-0,004$) e distiluse ($-0,000$), e fica francamente negativa em mpnet ($-0,145$), que erra 4 de 20 casos, recuperando o sentido oposto — por exemplo, diante da *query* “a perícia foi autorizada”, recupera “indeferiu a produção da prova pericial” acima de “deferiu”. A conclusão operacional é de *fragilidade*: o sinal de polaridade existe, mas é fino o suficiente para colapsar sob ruído, *query* pobre ou documento longo, condições rotineiras em acervos processuais reais.




Figura 3: Recuperação temática (20 cenários). À esquerda, taxa de acerto de *ranking* com IC95: os modelos distinguem na maioria dos casos. À direita, margens de cosseno: a margem média é positiva, mas a mínima toca ou cruza o zero, revelando a fragilidade do sinal.

4.4 O *cross-encoder* recupera parte da distinção, mas não a inversão de polo

A Figura 4 mostra o *cross-encoder* NLI. A probabilidade atribuída à classe *contradição* separa os grupos: média de 0,75 para os contrastivos contra 0,23 para o controle pareado. Mas a separação é desigual por estrato, e o detalhe é revelador. A negação adverbial e os quantificadores são detectados como contradição em 100% dos casos (6/6 e 4/4); a antonímia de núcleo, em 5/6. A inversão de polo, porém, é detectada em apenas 9 de 16 casos. A razão é instrutiva: “o autor deve indenizar o réu” e “o réu deve indenizar o autor” não constituem uma contradição lógica — ambas podem ser verdadeiras em situações distintas —, e sim uma inversão referencial que o próprio paradigma de inferência não captura. Isto fortalece, e não enfraquece, o argumento central: a inversão de polo é dura para *todas* as arquiteturas testadas, bi-encoder e *cross-encoder*, porque o problema não é de modelo, e sim de como a polaridade referencial é representada.




Figura 4: Distribuição de $P(\text{contradição})$ do *cross-encoder* NLI. A atenção cruzada recupera a distinção na negação e nos quantificadores, mas falha sistematicamente na inversão de polo (9/16).

4.5 Tabela completa

A Tabela 2 reporta as estatísticas por modelo e estrato, com IC95, para verificação. Nenhum valor foi selecionado ou suprimido.

Modelo	Estrato	μ	IC95 inf.	IC95 sup.	n
MiniLM	negacao_adverbial	0.550	0.479	0.623	6
MiniLM	antonimia_nucleo	0.724	0.569	0.874	6
MiniLM	inversao_polo	0.958	0.934	0.978	16
MiniLM	quant_modal	0.693	0.554	0.841	4
MiniLM	controle_parafrase	0.919	0.869	0.964	8
mpnet	negacao_adverbial	0.490	0.444	0.535	6
mpnet	antonimia_nucleo	0.769	0.647	0.892	6
mpnet	inversao_polo	0.967	0.941	0.987	16
mpnet	quant_modal	0.562	0.408	0.685	4
mpnet	controle_parafrase	0.940	0.886	0.977	8
distiluse	negacao_adverbial	0.844	0.808	0.875	6
distiluse	antonimia_nucleo	0.925	0.887	0.965	6
distiluse	inversao_polo	0.972	0.948	0.991	16
distiluse	quant_modal	0.901	0.843	0.939	4
distiluse	controle_parafrase	0.924	0.866	0.973	8

Tabela 2: Cosseno por modelo e estrato, com IC95 *bootstrap* (n pares por célula conforme a Tabela 1).

5 Por que isso é um problema linguístico, e não técnico

O operador poderia reagir à seção anterior dizendo: “ótimo, então preciso de um engenheiro que conserte o modelo”. A reação subestima o problema. Os resultados mostram que o *cross-encoder*, arquitetura mais cara que processa o par conjuntamente, recupera parte da distinção — mas falha exatamente onde o bi-encoder falha pior, na inversão de polo. Não se trata, portanto, de um defeito que uma engenharia melhor elimina, e sim de uma propriedade da escolha de representar significado por proximidade distribucional, escolha que é simultaneamente a fonte do poder desses modelos e a fonte de suas falhas mais perigosas para o Direito.

A consequência prática se manifesta na recuperação. Os resultados da Seção 4.3 desautorizam a afirmação simplista de que todo sistema vetorizado recupere o documento errado; mas autorizam, e fundamentam, a afirmação de que a margem que separa o precedente favorável do contrário é estreita e instável. Em um acervo de milhares de peças, com *queries* reais — frequentemente curtas, ambíguas e sem a intenção de polaridade explícita —, essa margem fina é precisamente onde a recuperação erra. O estudo de Stanford sobre ferramentas jurídicas, no nível do produto, observa que documentos apenas textualmente parecidos são recuperados como relevantes e acabam distraindo o sistema, degradando a resposta [4]; nossos resultados oferecem, no nível do componente, um dos mecanismos pelos quais isso ocorre.

A polaridade é o exemplo mais limpo do modelo lidando com o texto, mas a arquitetura tem outras camadas que agravam o problema. Há a sicofância, que a pesquisa de IA jurídica isolou como um dos modos de erro mais perigosos: o modelo foi desenhado, por alinhamento humano, para ser prestativo e agradável, não para buscar a verdade jurídica, e tende a espelhar a estrutura argumentativa que lhe é entregue. Nenhuma dessas falhas é visível para quem opera o sistema como se fosse um buscador. Todas são previsíveis para quem entende que está lidando com um modelo estatístico de linguagem. A diferença entre o operador competente e o exposto não é a quantidade de prompts que conhece. É a presença ou ausência de um modelo mental correto do que a máquina faz com a linguagem.

6 A escala do dano já documentada

Quem considera isto uma preocupação meramente teórica não acompanhou os números. Um estudo da Stanford RegLab sobre alucinação jurídica em modelos de propósito geral encontrou taxas entre 58% e 82% nas respostas a consultas jurídicas, com desempenho em doutrina substantiva que mal supera o chute aleatório [1]. Um segundo estudo, avaliando ferramentas jurídicas dedicadas que prometem ancorar respostas em fontes reais por recuperação aumentada, ainda

registrou 17% de alucinação no Lexis+ AI e 33% no Westlaw [4]. Recuperação aumentada reduz o problema; não o elimina. E se o passo de *embedding* preserva a polaridade apenas por margem tênue, a recuperação que alimenta o gerador já entrega material em que o sentido pode estar invertido.

E há o caso fundador, que todo operador deveria conhecer não como anedota, mas como diagnóstico. Em *Mata v. Avianca*, dois advogados protocolaram nos Estados Unidos uma peça com seis citações geradas por IA. Nenhum dos casos existia. O detalhe que importa é o seguinte: quando um dos advogados pediu ao modelo que confirmasse se as citações eram reais, ele confirmou, afirmando que poderiam ser encontradas nas bases jurídicas conhecidas [5]. O sistema não mentiu por malícia. Gerou a continuação estatisticamente mais provável para a pergunta “essas citações são reais?”, e a continuação mais provável, dado o contexto, era a confirmação. O operador interpretou isso como verificação. Era espelhamento. A sanção, registre-se, não veio da fabricação inicial, mas da insistência em não retratar depois de apontada a inexistência.

A lição não é “a IA erra, tome cuidado”. Essa lição é inútil porque não diz onde nem por que ela erra. A lição é que os erros têm uma gramática. Seguem a lógica da representação distribucional, e quem conhece essa gramática sabe antecipar onde o sistema é frágil: na polaridade, com severidade máxima na inversão de polo; na premissa falsa embutida; na citação de fonte que precisa existir mas pode não existir. O operador linguisticamente alfabetizado não confia menos na ferramenta de modo difuso. Ele desconfia de modo cirúrgico, nos pontos exatos onde a arquitetura prevê a fragilidade. É isto que constitui uma revisão humana responsável e eficiente de saída de IA.

7 O que muda quando o operador entende a linguagem da máquina

A perspectiva linguística não é um adorno acadêmico que se acrescenta à competência técnica. Ela reorganiza a prática inteira. Três deslocamentos concretos decorrem dela.

O primeiro é na verificação. Quem entende que o modelo gera a continuação mais plausível, e não a mais verdadeira, para de pedir ao próprio modelo que confirme os fatos que ele produziu, porque essa confirmação é mais texto plausível, não checagem. A verificação migra obrigatoriamente para fora do sistema, para a fonte primária, e isso deixa de ser recomendação genérica de prudência para virar consequência necessária da arquitetura.

O segundo é na formulação da entrada. Compreender o espelho reativo muda como se interroga o modelo. Em vez de entregar a tese pronta e pedir fundamentação, o que convida o sistema a espelhar e a fabricar suporte, o operador competente formula a consulta de modo a forçar o contraditório: pede a antítese, solicita as objeções mais fortes à própria posição, estrutura a entrada para que a máquina trabalhe contra a premissa e não a favor dela. Não é truque de prompt. É a aplicação direta de um entendimento sobre como o modelo processa a estrutura argumentativa que recebe.

O terceiro é na arquitetura dos sistemas que o próprio Direito está construindo. Quem vai projetar ou contratar um pipeline de recuperação jurídica precisa saber que a preservação da polaridade pelo *embedding* é frágil, com mínimo de robustez na inversão de polo, e que essa fragilidade exige mitigação explícita — um *reranker* de atenção cruzada, um tratamento dedicado de pares dialéticos, uma verificação de polaridade independente. As decisões de arquitetura — o tipo de *embedding*, a estratégia de fragmentação do texto, o uso ou não de *reranking*, o tratamento da referência de polo — são decisões linguísticas antes de serem decisões de engenharia, e o jurista que não as entende terceiriza para o fornecedor escolhas que determinam se o sistema vai sustentar ou sabotar o trabalho.

8 Limitações e ameaças à validade

A honestidade metodológica exige delimitar o alcance das medições. Primeiro, os 40 pares foram construídos por um único autor com expertise de domínio; ilustram mecanismos e fornecem estimativas com IC reportado, mas não estabelecem distribuições populacionais, e anotação independente é trabalho futuro necessário. Os estratos de quantificador/modal permanecem pequenos ($n = 4$) e suas estimativas são correspondentemente incertas. Segundo, medimos três modelos abertos multilíngues; modelos proprietários recentes, alguns treinados com sinal de inferência, podem atenuar o efeito, e a comparação fica registrada como extensão natural — o ponto do artigo não é que *todo embedding* falhe sempre, e sim que a preservação da polaridade é estruturalmente frágil e não pode ser pressuposta. Terceiro, a tarefa de recuperação usa um corpus mínimo de dois candidatos por *query*; ela isola a discriminação de polaridade, mas um acervo real introduz distratores que tendem a *piorar*, não melhorar, a margem observada. Nada disso enfraquece a tese central; enfraqueceria apenas uma versão caricata que afirmasse impossibilidade técnica determinística, e não é essa a afirmação deste artigo.

9 Conclusão

A tese, então, é esta. O operador do Direito não precisa abordar a operação de IA pela perspectiva linguística porque a linguística é elegante ou porque confere um verniz interdisciplinar ao currículo. Precisa porque o objeto que ele opera é, na sua natureza mais profunda, um artefato linguístico estatístico, e as falhas que esse artefato produz têm a forma da representação distribucional do significado. Este artigo tornou uma dessas falhas mensurável em português: a representação deficiente da polaridade. A medição corrige tanto o ceticismo ingênuo quanto o alarmismo. Não é verdade que esses sistemas sempre confundam afirmação e negação: em comparação lexicalmente pareada, dois de três modelos separam na média, e em recuperação realista os três acertam na maioria dos casos. É verdade, porém, que o fazem por margem tênue, que a inversão de polo resiste a toda arquitetura testada, e que a fragilidade resultante é invisível para quem opera o sistema como um buscador. Previsível para quem conhece a forma distribucional; invisível para quem a ignora.

A competência jurídica diz ao operador se um precedente é aplicável. Não lhe diz se a máquina o está recuperando porque o sustenta ou porque o contradiz, nem com que margem de segurança, nem se a confirmação que ele acabou de receber é verificação ou eco. Para responder a essas perguntas, que decidem se a IA será instrumento ou armadilha, é preciso uma alfabetização que a formação jurídica tradicional não fornece e que nenhum manual de atalhos substitui. É preciso entender a linguagem da máquina. Não a sintaxe dos comandos, mas a lógica de como ela representa, e deforma, o significado.

Disponibilidade de material. O conjunto de pares mínimos, o código de medição (bi-encoder, *cross-encoder* e tarefa de recuperação) e os resultados brutos que sustentam todas as figuras e tabelas são reproduzíveis com a biblioteca **sentence-transformers** em CPU, sem dependência de serviços proprietários.

Declaração sobre uso de IA. A redação foi assistida por ferramentas de IA sob revisão integral do autor. Os experimentos, dados e interpretação são de responsabilidade do autor. Esta declaração atende às diretrizes de transparência sobre uso de modelos de linguagem na preparação de manuscritos.

Referências

- [1] DAHL, M.; MAGESH, V.; SUZGUN, M.; HO, D. E. *Large Legal Fictions: Profiling Legal Hallucinations in Large Language Models*. Journal of Legal Analysis, v. 16, n. 1, p. 64–93, 2024. <https://doi.org/10.1093/jla/laae003>. Preprint: <https://arxiv.org/abs/2401.01301>.
- [2] ETTINGER, A. *What BERT Is Not: Lessons from a New Suite of Psycholinguistic Diagnostics for Language Models*. Transactions of the Association for Computational Linguistics, v. 8, p. 34–48, 2020. https://doi.org/10.1162/tac1_a_00298.
- [3] HARRIS, Z. S. *Distributional Structure*. Word, v. 10, n. 2–3, p. 146–162, 1954. <https://doi.org/10.1080/00437956.1954.11659520>.
- [4] MAGESH, V.; SURANI, F.; DAHL, M.; SUZGUN, M.; MANNING, C. D.; HO, D. E. *Hallucination-Free? Assessing the Reliability of Leading AI Legal Research Tools*. Journal of Empirical Legal Studies, 2025. <https://doi.org/10.1111/jels.12413>. Preprint: <https://arxiv.org/abs/2405.20362>.
- [5] ESTADOS UNIDOS. United States District Court for the Southern District of New York. *Mata v. Avianca, Inc.*, No. 22-cv-1461 (PKC). Opinion and Order on Sanctions, 22 jun. 2023. <https://www.law.berkeley.edu/wp-content/uploads/archive/2025/12/Mata-v-Avianca-Inc.pdf>.
- [6] REIMERS, N.; GUREVYCH, I. *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks*. In: Proceedings of EMNLP-IJCNLP, 2019, p. 3982–3992. <https://doi.org/10.18653/v1/D19-1410>.